

Reproduccion alternativa de gradient pathologies en PINNs

Difusion de calor 1D en una barra metalica

Trabajo practico de Optimizacion

Mayo 2026

Abstract

Se replica el nucleo metodologico de Wang, Teng y Perdikaris (*Understanding and mitigating gradient pathologies in physics-informed neural networks*) sobre un problema distinto: difusion de calor unidimensional en una barra metalica. Se comparan una PINN clasica (M1), una PINN con balance adaptativo de terminos de perdida basado en estadisticas de gradientes (M2) y la solucion analitica del problema. No se implementa la arquitectura nueva del paper. Tambien se incluye busqueda bayesiana de hiperparametros y una comparacion de optimizadores.

1 Problema fisico

La barra tiene longitud $L = 1$ m, difusividad termica $\alpha = 10^{-4}$ m²/s, extremos mantenidos a temperatura ambiente $T_{\text{amb}} = 20^\circ\text{C}$ y escala de temperatura $\Delta T = 80^\circ\text{C}$. La ecuacion dimensional es

$$\frac{\partial T}{\partial t} = \alpha \frac{\partial^2 T}{\partial X^2}, \quad 0 < X < L, \quad t > 0. \quad (1)$$

Las condiciones de borde son

$$T(0, t) = T(L, t) = T_{\text{amb}}. \quad (2)$$




Figure 1: Sistema de referencia para la barra metalica.

Se adimensionaliza con

$$x = \frac{X}{L}, \quad \tau = \frac{\alpha t}{L^2}, \quad u = \frac{T - T_{\text{amb}}}{\Delta T}. \quad (3)$$

El problema usado por la PINN es entonces

$$u_\tau - u_{xx} = 0, \quad 0 < x < 1, \quad 0 < \tau < \tau_f, \quad (4)$$

$$u(0, \tau) = u(1, \tau) = 0, \quad (5)$$

$$u(x, 0) = u_0(x), \quad (6)$$

donde $\tau_f = 0.25$, equivalente a $t_f = 2500$ s.

La condicion inicial es una suma de modos compatibles con los bordes:

$$u_0(x) = \sin(\pi x) + 0.5 \sin(3\pi x) + 0.25 \sin(5\pi x). \quad (7)$$

La solucion analitica por separacion de variables es

$$u(x, \tau) = \sum_{n \in \{1, 3, 5\}} a_n \sin(n\pi x) \exp(-(n\pi)^2 \tau), \quad (8)$$

con $(a_1, a_3, a_5) = (1, 0.5, 0.25)$.

2 Datos generados para la PINN

No se usa un dataset fijo de interior. En cada iteracion se generan nuevos minibatches:

$$x_r \sim \mathcal{U}(0, 1), \quad \tau_r \sim \mathcal{U}(0, \tau_f) \quad \text{residuo}, \quad (9)$$

$$x_0 \sim \mathcal{U}(0, 1), \quad \tau_0 = 0 \quad \text{condicion inicial}, \quad (10)$$

$$\tau_b \sim \mathcal{U}(0, \tau_f), \quad x_b \in \{0, 1\} \quad \text{bordes}. \quad (11)$$

En la corrida final se usa batch 256 para residuo, condicion inicial y borde. La mitad del batch de borde esta en $x = 0$ y la otra mitad en $x = 1$.

La grilla de evaluacion es regular, con $n_x = n_\tau = 180$. El error reportado es

$$\varepsilon_{L^2} = \frac{\|u_\theta - u_{\text{exacta}}\|_2}{\|u_{\text{exacta}}\|_2}. \quad (12)$$

3 PINN y perdidas

La red $u_\theta(x, \tau)$ es una MLP totalmente conectada con activacion tanh. Antes del primer layer se escala la entrada a $[-1, 1]^2$:

$$z = 2 \frac{[x, \tau] - [0, 0]}{[1, \tau_f] - [0, 0]} - 1. \quad (13)$$

La inicializacion es Xavier normal para pesos y cero para sesgos. La arquitectura principal final es

$$[2, 80, 80, 80, 1]. \quad (14)$$

Las perdidas son

$$L_{\text{res}} = \text{mean}((u_\tau - u_{xx})^2), \quad (15)$$

$$L_{\text{ic}} = \text{mean}((u_\theta(x, 0) - u_0(x))^2), \quad (16)$$

$$L_{\text{bc}} = \text{mean}(u_\theta(0, \tau)^2 + u_\theta(1, \tau)^2). \quad (17)$$

Las derivadas u_τ y u_{xx} se calculan con autograd de PyTorch.

4 Modelos comparados

El baseline M1 minimiza

$$L_{\text{M1}} = L_{\text{res}} + L_{\text{ic}} + L_{\text{bc}}. \quad (18)$$

El modelo M2 usa la correccion de balance adaptativo del paper:

$$L_{\text{M2}} = L_{\text{res}} + \lambda_{\text{ic}} L_{\text{ic}} + \lambda_{\text{bc}} L_{\text{bc}}. \quad (19)$$

Cada 10 iteraciones se estiman pesos instantaneos

$$\hat{\lambda}_i = \frac{\max_\theta |\nabla_\theta L_{\text{res}}|}{\text{mean}_\theta |\nabla_\theta L_i|}, \quad i \in \{\text{ic}, \text{bc}\}, \quad (20)$$

y se actualizan con media movil

$$\lambda_i \leftarrow \beta \lambda_i + (1 - \beta) \hat{\lambda}_i. \quad (21)$$

En la corrida final se usa $\beta = 0.9$. Las estadisticas se computan sobre los pesos de las capas lineales, como en el repositorio de los autores.




Figure 2: Flujo de entrenamiento para M2. M1 usa el mismo flujo sin actualizar pesos adaptativos.

5 Optimizacion e hiperparametros

La corrida principal usa Adam con learning rate inicial 0.0020667, sin weight decay, semilla 0, CPU y 16 threads. El scheduler es exponencial:

$$\eta_k = \eta_0 \left(0.9^{1/1000}\right)^k. \quad (22)$$

El entrenamiento principal dura 3000 iteraciones y usa arquitectura [2, 80, 80, 80, 1].

La busqueda bayesiana usa Optuna/TPE con 100 trials y 800 iteraciones por trial. El espacio explorado fue:

Parametro	Rango
ancho	{24, 32, 48, 64, 80}
profundidad	enteros de 2 a 5
learning rate	log-uniforme en $[10^{-4}, 3 \cdot 10^{-3}]$
batch	{128, 256, 384}
β adaptativo	uniforme en [0.75, 0.97]

6 Resultados

Modelo	error L^2 rel.	tiempo [s]	λ_{ic}	λ_{bc}
M1	0.264333	208.34	1.00	1.00
M2	0.028535	211.49	154084.83	251158.37

Table 1: Comparacion principal con arquitectura [2, 80, 80, 80, 1] y 3000 iteraciones.

La mejora de M1 a M2 fue $9.26\times$ en error relativo L^2 .




Figure 3: Error relativo L^2 contra solucion analitica.




Figure 4: Solucion exacta, prediccion M1 y error absoluto.




Figure 5: Solucion exacta, prediccion M2 y error absoluto.




Figure 6: Cortes espaciales en tiempos adimensionales fijos.




Figure 7: Figura resumen tipo paper: solucion exacta, M1, M2 y errores.

7 Gradientes y sensibilidad

Los histogramas de gradientes reproducen el analisis cualitativo del paper: se inspeccionan los gradientes de L_{res} , L_{ic} y L_{bc} por capa para detectar desbalance entre terminos.




Figure 8: Histogramas de gradientes por capa para M1.




Figure 9: Histogramas de gradientes por capa para M2.

El mejor trial corto de la búsqueda bayesiana fue el trial 91 (width = 80, depth = 4, $\eta = 0.001414$, batch 384 y $\beta = 0.96918$), con error corto 0.03197. Sin embargo, la validación larga de los 6 mejores trials mostro que el mejor regimen sostenido fue el trial 82: width = 80, depth = 3, $\eta = 0.0020667$, batch 256 y $\beta = 0.96094$. Este regimen obtuvo error validado 0.02842 para M2.




Figure 10: Magnitud media de gradientes por capa para M1 y M2.




Figure 11: Evolucion de pesos adaptativos en M2, analoga al grafico de lambdas del paper.




Figure 12: Sensibilidad entre error corto de Optuna y error validado a 3000 iteraciones.

8 Búsqueda bayesiana y optimizadores




Figure 13: Historia de trials y mejor error acumulado en la búsqueda bayesiana.




Figure 14: Error contra parametros explorados por Optuna/TPE.




Figure 15: Mejor error observado por ancho y profundidad.




Figure 16: Validacion larga de los mejores trials de Optuna y del regimen conservador.




Figure 17: Robustez con tres semillas. M2: 0.0551 ± 0.0232 ; M1: 0.2401 ± 0.0225 .

La comparacion de optimizadores se hizo con presupuesto fijo y M2:

Optimizador	error L^2 rel.	tiempo [s]
Adam, $\text{lr}=5 \cdot 10^{-4}$	0.167167	68.63
AdamW, $\text{lr}=5 \cdot 10^{-4}$	0.167167	71.72
Adam $\text{lr}=5 \cdot 10^{-4}$ + LBFGS(10)	0.167244	69.13
Adam, $\text{lr}=10^{-3}$	0.176340	69.26
SGD, $\text{lr}=10^{-4}$, momentum=0.9	0.220924	70.58

Table 2: Comparacion de optimizadores con 1000 iteraciones, batch 128 y arquitectura [2, 32, 32, 32, 1].




Figure 18: Comparacion grafica de optimizadores con learning rates ajustados por familia.

9 Graficos analogos al notebook de examen

Se reviso el notebook de examen `jurado_german_parcial.ipynb`, ubicado en el directorio local `ejemplos_figuras_examen`. Alli se grafican $f(x_k)$, $\|\nabla f(x_k)\|$ y trayectorias sobre contornos para una funcion objetivo de dos variables. En una PINN no hay una trayectoria 2D natural en el espacio de pesos, porque la red tiene miles de parametros. Por eso se trasladaron esos graficos al espacio interpretable de hiperparametros: cada trial de Optuna es un punto de la trayectoria y el plano usado es $\log_{10}(\eta)$ contra β adaptativo.

Las curvas de perdida de M1/M2 y la historia de Optuna cubren el analogo de $f(x_k)$. Los gradientes se documentan con histogramas y magnitudes medias por capa, que es el diagnostico usado por el paper. Como complemento, las siguientes figuras muestran convergencia de Optuna y trayectorias tipo examen en el espacio de busqueda.




Figure 19: Analogo de $f(x_k)$ para la busqueda bayesiana: error por trial y mejor acumulado.




Figure 20: Trayectoria de Optuna sobre contornos interpolados de $\log_{10}(\text{error})$ en el plano $\log_{10}(\eta)$ - β .




Figure 21: Sensibilidad de los optimizadores al learning rate y ranking con presupuesto fijo.

10 Reproducibilidad

Los comandos principales fueron:

```
conda env create -f environment.yml
conda activate tp-optimizacion-ger
```

```
python experimento.py bayes --trials 100 --target-trials --search-iters 800 \
    --storage sqlite:///outputs/optuna_calor_1d.db --study-name calor_1d_m2_100 \
    --threads 16
```

```
python validar_regimenes.py --top-k 6 --iters 3000 --threads 16

python experimento.py todos \
  --iters 3000 --batch 256 --width 80 --depth 3 \
  --lr 0.0020667030862179673 --adaptive-beta 0.9609402971992413 \
  --log-every 500 --nx 180 --nt 180 --threads 16

python experimento.py semillas --seeds 0 1 2 \
  --iters 3000 --batch 256 --width 80 --depth 3 \
  --lr 0.0020667030862179673 --adaptive-beta 0.9609402971992413 \
  --log-every 1000 --nx 120 --nt 120 --threads 16

python experimento.py optimizadores \
  --iters 1000 --batch 128 --width 32 --depth 3 \
  --adaptive-beta 0.9 \
  --log-every 500 --nx 120 --nt 120 \
  --lbfgs-steps 10 --threads 16

python analisis_sensibilidad.py
python plots_examen.py
tectonic reporte.tex
```