

Reproduccion alternativa de gradient pathologies en PINNs

Difusion de calor 1D en una barra metalica

Trabajo practico de Optimizacion

Mayo 2026

Abstract

Se replica el nucleo metodologico de Wang, Teng y Perdikaris (*Understanding and mitigating gradient pathologies in physics-informed neural networks*) sobre un problema distinto: difusion de calor unidimensional en una barra metalica. Se comparan una PINN clasica (M1), una PINN clasica optimizada de forma independiente (M1B), una PINN con balance adaptativo de terminos de perdida basado en estadisticas de gradientes (M2) y la solucion analitica del problema. No se implementa la arquitectura nueva del paper. Tambien se incluye busqueda bayesiana de hiperparametros y una comparacion de optimizadores.

1 Problema fisico

La barra tiene longitud $L = 1$ m, difusividad termica $\alpha = 10^{-4}$ m²/s, extremos mantenidos a temperatura ambiente $T_{\text{amb}} = 20^\circ\text{C}$ y escala de temperatura $\Delta T = 80^\circ\text{C}$. La ecuacion dimensional es

$$\frac{\partial T}{\partial t} = \alpha \frac{\partial^2 T}{\partial X^2}, \quad 0 < X < L, \quad t > 0. \quad (1)$$

Las condiciones de borde son

$$T(0, t) = T(L, t) = T_{\text{amb}}. \quad (2)$$




Figure 1: Sistema de referencia para la barra metalica.

Se adimensionaliza con

$$x = \frac{X}{L}, \quad \tau = \frac{\alpha t}{L^2}, \quad u = \frac{T - T_{\text{amb}}}{\Delta T}. \quad (3)$$

El problema usado por la PINN es entonces

$$u_\tau - u_{xx} = 0, \quad 0 < x < 1, \quad 0 < \tau < \tau_f, \quad (4)$$

$$u(0, \tau) = u(1, \tau) = 0, \quad (5)$$

$$u(x, 0) = u_0(x), \quad (6)$$

donde $\tau_f = 0.25$, equivalente a $t_f = 2500$ s.

La condicion inicial es una suma de modos compatibles con los bordes:

$$u_0(x) = \sin(\pi x) + 0.5 \sin(3\pi x) + 0.25 \sin(5\pi x). \quad (7)$$

La solucion analitica por separacion de variables es

$$u(x, \tau) = \sum_{n \in \{1,3,5\}} a_n \sin(n\pi x) \exp(-(n\pi)^2 \tau), \quad (8)$$

con $(a_1, a_3, a_5) = (1, 0.5, 0.25)$.

2 Datos generados para la PINN

No se usa un dataset fijo de interior. En cada iteracion se generan nuevos minibatches:

$$x_r \sim \mathcal{U}(0, 1), \quad \tau_r \sim \mathcal{U}(0, \tau_f) \quad \text{residuo}, \quad (9)$$

$$x_0 \sim \mathcal{U}(0, 1), \quad \tau_0 = 0 \quad \text{condicion inicial}, \quad (10)$$

$$\tau_b \sim \mathcal{U}(0, \tau_f), \quad x_b \in \{0, 1\} \quad \text{bordes}. \quad (11)$$

En la corrida final se usa batch 256 para residuo, condicion inicial y borde. La mitad del batch de borde esta en $x = 0$ y la otra mitad en $x = 1$.

La grilla de evaluacion es regular, con $n_x = n_\tau = 180$. El error reportado es

$$\varepsilon_{L^2} = \frac{\|u_\theta - u_{\text{exacta}}\|_2}{\|u_{\text{exacta}}\|_2}. \quad (12)$$

3 PINN y perdidas

La red $u_\theta(x, \tau)$ es una MLP totalmente conectada con activacion tanh. Antes del primer layer se escala la entrada a $[-1, 1]^2$:

$$z = 2 \frac{[x, \tau] - [0, 0]}{[1, \tau_f] - [0, 0]} - 1. \quad (13)$$

La inicializacion es Xavier normal para pesos y cero para sesgos. La arquitectura principal final es

$$[2, 80, 80, 80, 1]. \quad (14)$$

Las perdidas son

$$L_{\text{res}} = \text{mean}((u_\tau - u_{xx})^2), \quad (15)$$

$$L_{\text{ic}} = \text{mean}((u_\theta(x, 0) - u_0(x))^2), \quad (16)$$

$$L_{\text{bc}} = \text{mean}(u_\theta(0, \tau)^2 + u_\theta(1, \tau)^2). \quad (17)$$

Las derivadas u_τ y u_{xx} se calculan con autograd de PyTorch.

4 Modelos comparados

El baseline M1 minimiza

$$L_{\text{M1}} = L_{\text{res}} + L_{\text{ic}} + L_{\text{bc}}. \quad (18)$$

El modelo M1B usa exactamente la misma perdida que M1, pero sus hiperparametros se eligen con una busqueda bayesiana propia. M1B no es una mejora propuesta por el paper; es una ablacion agregada para separar el efecto del tuning del efecto del balance adaptativo.

El modelo M2 usa la correccion de balance adaptativo del paper:

$$L_{\text{M2}} = L_{\text{res}} + \lambda_{\text{ic}} L_{\text{ic}} + \lambda_{\text{bc}} L_{\text{bc}}. \quad (19)$$

Cada 10 iteraciones se estiman pesos instantaneos

$$\hat{\lambda}_i = \frac{\max_\theta |\nabla_\theta L_{\text{res}}|}{\text{mean}_\theta |\nabla_\theta L_i|}, \quad i \in \{\text{ic}, \text{bc}\}, \quad (20)$$

y se actualizan con media movil

$$\lambda_i \leftarrow \beta \lambda_i + (1 - \beta) \hat{\lambda}_i. \quad (21)$$

En la corrida final se usa $\beta = 0.9609403$. Las estadisticas se computan sobre los pesos de las capas lineales, como en el repositorio de los autores.




Figure 2: Flujo de entrenamiento para M2. M1 usa el mismo flujo sin actualizar pesos adaptativos.

5 Optimizacion e hiperparametros

La corrida principal usa Adam con learning rate inicial 0.0020667, sin weight decay, semilla 0, CPU y 16 threads. El scheduler es exponencial:

$$\eta_k = \eta_0 \left(0.9^{1/1000}\right)^k. \quad (22)$$

El entrenamiento principal dura 3000 iteraciones y usa arquitectura [2, 80, 80, 80, 1].

La busqueda bayesiana principal usa Optuna/TPE con 100 trials y 800 iteraciones por trial sobre M2. El espacio explorado fue:

Parametro	Rango
ancho	{24, 32, 48, 64, 80}
profundidad	enteros de 2 a 5
learning rate	log-uniforme en $[10^{-4}, 3 \cdot 10^{-3}]$
batch	{128, 256, 384}
β adaptativo	uniforme en [0.75, 0.97]

Para M1B se repitio la busqueda con el mismo presupuesto, pero sin β adaptativo, porque M1B mantiene $\lambda_{ic} = \lambda_{bc} = 1$.

6 Resultados

Modelo	error L^2 rel.	tiempo [s]	λ_{ic}	λ_{bc}
M1	0.264333	208.34	1.00	1.00
M1B	0.182104	343.35	1.00	1.00
M2	0.028535	211.49	154084.83	251158.37

Table 1: Comparacion principal y ablacion M1B con 3000 iteraciones. M1 y M2 usan la arquitectura [2, 80, 80, 80, 1]; M1B usa la arquitectura optimizada [2, 48, 48, 48, 48, 1].

La mejora de M1 a M2 fue $9.26\times$ en error relativo L^2 . La optimizacion separada de M1 produjo M1B y mejoro a M1 por $1.45\times$, pero M1B todavia quedo $6.38\times$ por encima del error de M2.




Figure 3: Error relativo L^2 contra solucion analitica.




Figure 4: Comparacion extra con M1B, la M1 optimizada sin pesos adaptativos.




Figure 5: Solucion exacta, prediccion M1 y error absoluto.




Figure 6: Solucion exacta, prediccion M1B y error absoluto.




Figure 7: Solucion exacta, prediccion M2 y error absoluto.




Figure 8: Cortes espaciales en tiempos adimensionales fijos.




Figure 9: Figura resumen tipo paper: solucion exacta, M1, M2 y errores.

7 Gradientes y sensibilidad

Los histogramas de gradientes reproducen el analisis cualitativo del paper: se inspeccionan los gradientes de L_{res} , L_{ic} y L_{bc} por capa para detectar desbalance entre terminos.




Figure 10: Histogramas de gradientes por capa para M1.




Figure 11: Histogramas de gradientes por capa para M1B.




Figure 12: Histogramas de gradientes por capa para M2.

El mejor trial corto de la búsqueda bayesiana fue el trial 91 (width = 80, depth = 4, $\eta = 0.001414$, batch 384 y $\beta = 0.96918$), con error corto 0.03197. Sin embargo, la validación larga de los 6 mejores trials mostro que el mejor regimen sostenido fue el trial 82: width = 80, depth = 3, $\eta = 0.0020667$, batch 256 y $\beta = 0.96094$. Este regimen obtuvo error validado 0.02842 para M2.

Para M1B se hizo otra búsqueda Optuna/TPE sin β adaptativo. El mejor trial corto fue el 91 (width = 48, depth = 5, $\eta = 0.0010009$, batch 128), con error corto 0.26293. La validación larga de los 6 mejores trials eligio el trial 83: width = 48, depth = 5, $\eta = 0.0020996$ y batch 128. Ese regimen obtuvo error validado 0.18460 y error final 0.18210 en grilla 180×180 .




Figure 13: Magnitud media de gradientes por capa para M1 y M2.




Figure 14: Evolucion de pesos adaptativos en M2, analoga al grafico de lambdas del paper.




Figure 15: Sensibilidad entre error corto de Optuna y error validado a 3000 iteraciones.

8 Búsqueda bayesiana y optimizadores




Figure 16: Historia de trials y mejor error acumulado en la búsqueda bayesiana.




Figure 17: Error contra parametros explorados por Optuna/TPE.




Figure 18: Mejor error observado por ancho y profundidad.




Figure 19: Historia de trials y mejor error acumulado en la busqueda bayesiana de M1B.




Figure 20: Error de M1B contra parametros explorados por Optuna/TPE.




Figure 21: Mejor error M1B observado por ancho y profundidad.




Figure 22: Validacion larga de los mejores trials de Optuna y del regimen conservador.




Figure 23: Validacion larga de los mejores trials de Optuna para M1B.




Figure 24: Robustez con tres semillas. M2: 0.0551 ± 0.0232 ; M1: 0.2401 ± 0.0225 .

La comparacion de optimizadores se hizo con presupuesto fijo y M2:

Optimizador	error L^2 rel.	tiempo [s]
Adam, lr= $5 \cdot 10^{-4}$	0.167167	68.63
AdamW, lr= $5 \cdot 10^{-4}$	0.167167	71.72
Adam lr= $5 \cdot 10^{-4}$ + LBFGS(10)	0.167244	69.13
Adam, lr= 10^{-3}	0.176340	69.26
SGD, lr= 10^{-4} , momentum=0.9	0.220924	70.58

Table 2: Comparacion de optimizadores con 1000 iteraciones, batch 128 y arquitectura [2, 32, 32, 32, 1].




Figure 25: Comparacion grafica de optimizadores con learning rates ajustados por familia.

9 Graficos analogos al notebook de examen

Se reviso el notebook de examen `jurado_german_parcial.ipynb`, ubicado en el directorio local `ejemplos_figuras_examen`. Alli se grafican $f(x_k)$, $\|\nabla f(x_k)\|$ y trayectorias sobre contornos para una funcion objetivo de dos variables. En una PINN no hay una trayectoria 2D natural en el espacio de pesos, porque la red tiene miles de parametros. Por eso se trasladaron esos graficos al espacio interpretable de hiperparametros: cada trial de Optuna es un punto de la trayectoria. Para M2 el plano usado es $\log_{10}(\eta)$ contra β adaptativo; para M1B, que no tiene β , se usa $\log_{10}(\eta)$ contra ancho de red.

Las curvas de perdida de M1/M2 y la historia de Optuna cubren el analogo de $f(x_k)$. Los gradientes se documentan con histogramas y magnitudes medias por capa, que es el diagnostico usado por el paper. Como complemento, las siguientes figuras muestran convergencia de Optuna y trayectorias tipo examen en el espacio de busqueda.




Figure 26: Análogo de $f(x_k)$ para la búsqueda bayesiana: error por trial y mejor acumulado.




Figure 27: Trayectoria de Optuna sobre contornos interpolados de $\log_{10}(\text{error})$ en el plano $\log_{10}(\eta)$ - β .




Figure 28: Análogo de $f(x_k)$ para la búsqueda bayesiana de M1B.




Figure 29: Trayectoria de Optuna para M1B en el plano $\log_{10}(\eta)$ -ancho.




Figure 30: Sensibilidad de los optimizadores al learning rate y ranking con presupuesto fijo.

10 Reproducibilidad

Los comandos principales fueron:

```
conda env create -f environment.yml
conda activate tp-optimizacion-ger
```

```
python experimento.py bayes --trials 100 --target-trials --search-iters 800 \
  --storage sqlite:///outputs/optuna_calor_1d.db --study-name calor_1d_m2_100 \
  --threads 16
```

```
python validar_regimenes.py --top-k 6 --iters 3000 --threads 16
```

```
python experimento.py bayes-m1 --trials 100 --target-trials --search-iters 800 \
  --storage sqlite:///outputs/optuna_calor_1d_m1.db --study-name calor_1d_m1_100 \
  --threads 16
```

```
python validar_m1b.py --top-k 6 --iters 3000 --threads 16
```

```
python experimento.py todos \
  --iters 3000 --batch 256 --width 80 --depth 3 \
  --lr 0.0020667030862179673 --adaptive-beta 0.9609402971992413 \
  --log-every 500 --nx 180 --nt 180 --threads 16
```

```
python experimento.py m1b \
  --iters 3000 --log-every 500 --nx 180 --nt 180 --threads 16
```

```
python experimento.py semillas --seeds 0 1 2 \
  --iters 3000 --batch 256 --width 80 --depth 3 \
  --lr 0.0020667030862179673 --adaptive-beta 0.9609402971992413 \
  --log-every 1000 --nx 120 --nt 120 --threads 16
```

```
python experimento.py optimizadores \
  --iters 1000 --batch 128 --width 32 --depth 3 \
  --adaptive-beta 0.9 \
  --log-every 500 --nx 120 --nt 120 \
```

```
--lbfgs-steps 10 --threads 16
```

```
python analisis_sensibilidad.py
```

```
python plots_examen.py
```

```
tectonic reporte.tex
```