

Resumen del paper y aplicacion al proyecto

Gradient pathologies en PINNs para difusion de calor 1D

Trabajo practico de Optimizacion

Mayo 2026

Abstract

Este reporte resume el nucleo conceptual del trabajo de Wang, Teng y Perdikaris, *Understanding and mitigating gradient pathologies in physics-informed neural networks*, y documenta como se traslado esa metodologia al proyecto de difusion de calor unidimensional. El foco no es reproducir los benchmarks originales del paper, sino replicar su diagnostico central: las PINNs pueden fallar por desbalance de gradientes entre el residuo de la PDE y las restricciones fisicas. En nuestro proyecto se compara una PINN clasica (M1), una PINN con pesos adaptativos basados en gradientes (M2) y la solucion analitica de la ecuacion de calor. Como ablacion adicional, tambien se entrena M1B: una M1 optimizada de forma independiente, sin pesos adaptativos.

1 Idea central del paper

Las physics-informed neural networks aproximan una solucion continua $u(x, t)$ mediante una red neuronal $u_\theta(x, t)$ y entrenan sus parametros para satisfacer simultaneamente datos, condiciones iniciales o de borde, y una ecuacion diferencial. Para un problema general

$$u_t + \mathcal{N}_x[u] = 0, \quad (1)$$

$$u(x, 0) = h(x), \quad (2)$$

$$u(x, t) = g(x, t), \quad x \in \partial\Omega, \quad (3)$$

el residuo de la PDE se escribe como

$$r_\theta(x, t) = \frac{\partial u_\theta}{\partial t}(x, t) + \mathcal{N}_x[u_\theta](x, t), \quad (4)$$

donde las derivadas se calculan por diferenciacion automatica.

La perdida de una PINN es compuesta:

$$\mathcal{L}(\theta) = \mathcal{L}_r(\theta) + \sum_{i=1}^M \lambda_i \mathcal{L}_i(\theta). \quad (5)$$

Aqui $\mathcal{L}_r$ penaliza el residuo de la PDE y los terminos $\mathcal{L}_i$ penalizan restricciones fisicas o datos, por ejemplo condicion inicial y condiciones de borde. La observacion del paper es que estos terminos no solo tienen escalas distintas en valor, sino tambien gradientes retropropagados muy distintos. Cuando una restriccion fisica tiene gradientes mucho menores que el residuo, el optimizador puede reducir la PDE residual sin aprender correctamente las condiciones que hacen unica a la solucion.

2 Patologia de gradientes y rigidez

El paper muestra que una PINN clasica puede quedar sesgada hacia satisfacer el residuo diferencial e ignorar restricciones de borde o datos. El diagnostico no se hace mirando solamente la perdida total, sino separando los gradientes de cada termino:

$$\nabla_\theta \mathcal{L}_r, \quad \nabla_\theta \mathcal{L}_{u_b}, \quad \nabla_\theta \mathcal{L}_{u_0}. \quad (6)$$

En sus experimentos, los histogramas por capa muestran que los gradientes de las condiciones de borde pueden concentrarse cerca de cero mientras los del residuo permanecen grandes. Ese es el mecanismo al que denominan *gradient pathologies*.

La segunda lectura del paper es dinamica. El descenso por gradiente discretiza el flujo continuo

$$\frac{d\theta}{dt} = -\nabla_{\theta}\mathcal{L}_r(\theta) - \sum_{i=1}^M \nabla_{\theta}\mathcal{L}_i(\theta). \quad (7)$$

Si el flujo es rigido, el paso de aprendizaje queda severamente restringido por los autovalores grandes del Hessiano. En terminos numericos, descenso por gradiente se comporta como Euler explicito: un paso demasiado grande puede no disminuir la perdida aunque la direccion de gradiente sea localmente correcta. Esta interpretacion conecta la dificultad de entrenar PINNs con problemas clasicos de estabilidad numerica.

3 Correccion propuesta por los autores

El paper propone dos remedios:

- una regla adaptativa de pesos de perdida basada en estadisticas de gradientes;
- una arquitectura fully connected modificada para reducir rigidez.

En este proyecto solo se replica el primer remedio. No usamos la arquitectura nueva de los autores. La regla que si usamos corresponde al algoritmo de learning-rate annealing del paper, que reescala cada termino de dato o restriccion:

$$\mathcal{L}_{M2} = \mathcal{L}_r + \lambda_{ic}\mathcal{L}_{ic} + \lambda_{bc}\mathcal{L}_{bc}. \quad (8)$$

La estimacion instantanea de cada peso se calcula con estadisticas de gradiente:

$$\hat{\lambda}_i = \frac{\max_{\theta} |\nabla_{\theta}\mathcal{L}_r|}{\text{mean}_{\theta} |\nabla_{\theta}\mathcal{L}_i|}, \quad i \in \{ic, bc\}. \quad (9)$$

En nuestra implementacion se sigue la convencion del repositorio de los autores, usando una media movil

$$\lambda_i \leftarrow \beta\lambda_i + (1 - \beta)\hat{\lambda}_i. \quad (10)$$

Por lo tanto, si los gradientes de condicion inicial o borde son pequenos frente al residuo, sus pesos aumentan y el paso efectivo asociado a esas restricciones se amplifica.

Modelo del paper	Significado	En este proyecto
M1	PINN clasica	Implementado
M2	PINN + pesos adaptativos	Implementado
M3	Nueva arquitectura	No implementado
M4	M2 + nueva arquitectura	No implementado

Table 1: Alcance de la reproduccion alternativa.

4 Traslado al problema de calor 1D

El problema elegido es la difusion de calor en una barra metalica. Con $x = X/L$, $\tau = \alpha t/L^2$ y $u = (T - T_{\text{amb}})/\Delta T$, se resuelve

$$u_{\tau} - u_{xx} = 0, \quad 0 < x < 1, \quad 0 < \tau < 0.25, \quad (11)$$

$$u(0, \tau) = u(1, \tau) = 0, \quad (12)$$

$$u(x, 0) = \sin(\pi x) + 0.5 \sin(3\pi x) + 0.25 \sin(5\pi x). \quad (13)$$

La solucion analitica usada como referencia es

$$u(x, \tau) = \sum_{n \in \{1, 3, 5\}} a_n \sin(n\pi x) \exp[-(n\pi)^2 \tau], \quad (a_1, a_3, a_5) = (1, 0.5, 0.25). \quad (14)$$




Figure 1: Trazabilidad entre el paper original y el experimento de calor 1D.

La correspondencia metodologica es:

Idea del paper	Adaptacion en el proyecto
PINN clasica como baseline	M1 con $\mathcal{L}_r + \mathcal{L}_{ic} + \mathcal{L}_{bc}$
Diagnostico por gradientes separados	Histogramas y magnitudes medias por capa para $\mathcal{L}_r$, $\mathcal{L}_{ic}$ y $\mathcal{L}_{bc}$
Learning-rate annealing por gradientes	M2 con λ_{ic} y λ_{bc} actualizados cada 10 iteraciones
Comparacion contra solucion conocida	Error relativo L^2 contra la solucion analitica por separacion de variables
Robustez y sensibilidad	Optuna con 100 trials, validacion larga, semillas extra y comparacion de optimizadores

Table 2: Mapa entre el nucleo metodologico del paper y nuestra implementacion.

5 Que observamos en nuestro proyecto

La arquitectura principal final fue $[2, 80, 80, 80, 1]$ con activacion tanh, inicializacion Xavier normal, Adam, 3000 iteraciones y batch 256. Los hiperparametros fueron seleccionados mediante 100 trials de Optuna/TPE y una validacion larga de los mejores regimenes.

Adicionalmente, se entreno M1B para separar el efecto del tuning de hiperparametros del efecto del balance adaptativo. M1B mantiene $\lambda_{ic} = \lambda_{bc} = 1$ y usa una busqueda bayesiana propia.

Modelo	error L^2 rel.	tiempo [s]	λ_{ic} final	λ_{bc} final
M1	0.264333	208.34	1.00	1.00
M1B	0.182104	343.35	1.00	1.00
M2	0.028535	211.49	154084.83	251158.37

Table 3: Resultado principal sobre calor 1D. M2 reduce el error de M1 por un factor $9.26\times$. M1B mejora a M1 por tuning, pero queda $6.38\times$ por encima de M2.

El resultado confirma la idea operativa del paper: el reescalado adaptativo de los terminos de condicion inicial y borde puede cambiar de forma importante el entrenamiento. En este problema, los pesos finales de M2 son muy grandes, lo que indica que las estadisticas de gradiente detectaron contribuciones de restriccion mucho mas debiles que la referencia del residuo.




Figure 2: Comparacion del error relativo L^2 entre M1 y M2.




Figure 3: Ablacion extra: comparacion de M1, M1B y M2.




Figure 4: Solucion analitica, predicciones M1/M2 y mapas de error.




Figure 5: Diagnostico heredado del paper: magnitud media de gradientes por capa y por termino de perdida.




Figure 6: Evolucion de los pesos adaptativos de M2.

6 Hiperparametros y optimizacion

El paper advierte que no existe una receta fija de pesos λ_i que sea transferible entre PDEs. Por eso, ademas de implementar M2, se hizo busqueda bayesiana de hiperparametros. Para M2, el espacio explorado fue ancho de red, profundidad, learning rate, batch y β adaptativo. La busqueda corta eligio como mejor trial al 91, pero la validacion larga selecciono el trial 82:

$$\text{width} = 80, \quad \text{depth} = 3, \quad \eta = 0.0020667, \quad \text{batch} = 256, \quad \beta = 0.96094.$$

Esta diferencia entre el mejor trial corto y el mejor regimen validado es coherente con el mensaje del paper: la optimizacion de PINNs debe evaluarse por estabilidad y error final, no solo por una perdida temprana.

La busqueda extra de M1B uso el mismo presupuesto, pero sin β . El mejor regimen validado fue el trial 83:

$$\text{width} = 48, \quad \text{depth} = 5, \quad \eta = 0.0020996, \quad \text{batch} = 128,$$

con error final 0.1821 en grilla 180×180 .




Figure 7: Historia de Optuna: objetivo por trial y mejor acumulado.




Figure 8: Trayectoria de búsqueda en el plano $\log_{10}(\eta)$ - β .




Figure 9: Trayectoria de búsqueda M1B en el plano $\log_{10}(\eta)$ -ancho.




Figure 10: Comparacion de optimizadores con presupuesto fijo.

7 Lectura final

El paper no debe leerse solamente como una propuesta de arquitectura, sino como un analisis de optimizacion para perdidas compuestas. La leccion principal es que, en PINNs, cumplir la PDE y cumplir las restricciones fisicas son objetivos acoplados pero no igualmente visibles para el optimizador. Si el residuo domina los gradientes, una red puede parecer fisicamente informada y aun asi aproximar mal la solucion correcta.

En nuestro problema de calor 1D se observa el mismo patron metodologico:

- M1 usa la formulacion clasica y alcanza un error relativo 0.2643.
- M1B optimiza la M1 clasica y baja el error a 0.1821, por lo que el tuning ayuda pero no elimina la patologia.
- M2 usa el balance adaptativo del paper y alcanza 0.0285.
- La mejora no depende de cambiar la PDE ni de usar la arquitectura nueva; surge de modificar la geometria efectiva de la optimizacion.
- Los graficos de gradientes y lambdas muestran el mecanismo que explica la mejora, no solo el resultado numerico final.

La reproduccion es, por diseno, alternativa: no replica los ejemplos de Helmholtz, Klein-Gordon o Navier-Stokes del paper, y no implementa M3/M4. Lo que si replica es el nucleo tecnico que la consigna pide estudiar: diagnosticar patologias de gradiente en PINNs y mitigarlas mediante pesos adaptativos calculados a partir de estadisticas de gradiente.

References

- [1] S. Wang, Y. Teng, and P. Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5):A3055–A3081, 2021.
- [2] Predictive Intelligence Lab. GradientPathologiesPINNs. <https://github.com/PredictiveIntelligenceLab/GradientPathologiesPINNs>.